



# MNEMOLITE

PostgreSQL-Native Cognitive Memory

## L'ENFER DE L'AMNÉSIE IA (2025)

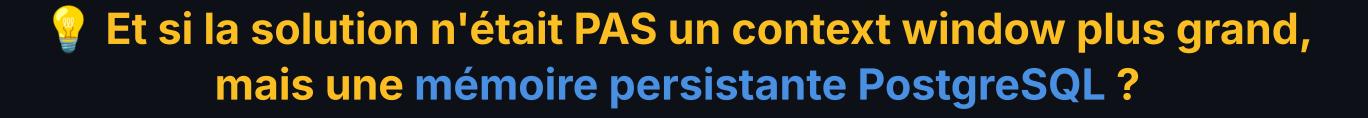
"Désolé, je ne me souviens pas de notre conversation d'hier..."

### **LE COÛT CACHÉ DE L'AMNÉSIE:**

Coût GPT-4 Turbo	\$1-2 / conversation longue (20 échanges)
Frustration Utilisateurs	77% trouvent chatbots frustrants (2024)
Abandon Clients	91% partent sans se plaindre (UX research)
Context Window Growth	30× par an depuis 2023 (Epoch AI)

#### 🔥 LE VRAI PROBLÈME:

- **Context windows limités** (même Gemini 10M tokens) → Memory inflation → coûts explosifs
- ▶ **Dégradation contextuelle**  $\rightarrow$  Info critique perdue  $\rightarrow$  UX catastrophique
- **Bigger context"** ≠ **Solution** → Besoin d'une VRAIE mémoire persistante



## LE PROBLÈME DES SOLUTIONS EXISTANTES

#### PINECONE, WEAVIATE, MILVUS

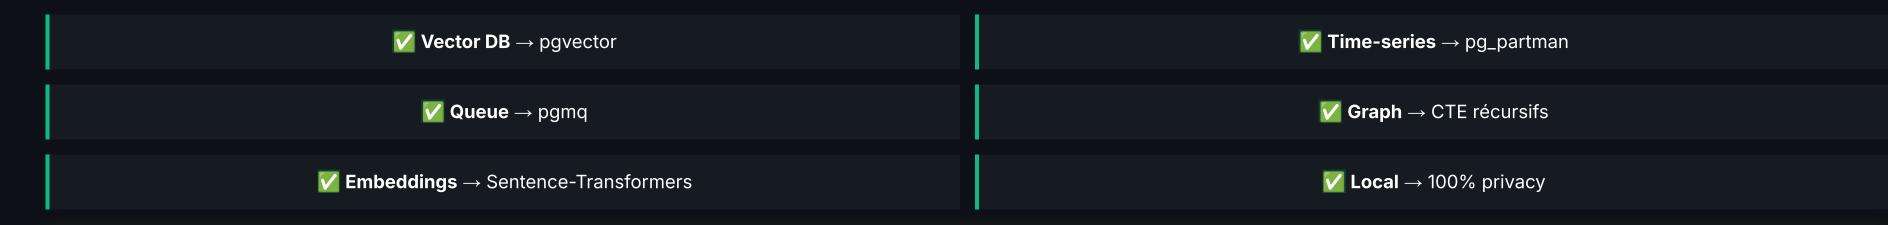
- Cloud-only ou self-hosting complexe
- Coûts récurrents (\$25-500+/mois)
- Latence réseau (50-200ms)
- Dépendance OpenAI (\$\$\$)

#### **SOLUTIONS DIY (REDIS + SQLITE + ...)**

- Stack technique fragmentée
- ► X Maintenance cauchemardesque
- Scalabilité limitée
- Pas de graph natif

@ Besoin: Solution simple, locale, performante, unifiée







Zéro dépendance externe • Zéro coût cloud • 100% privacy



### **≠** PGVECTOR 0.8.0 - RÉVOLUTION

Sortie: 30 octobre 2024

- ▶ 9.4× Plus Rapide 123ms → 13ms (scans itératifs)
- ➤ Surpasse les DB Spécialisées Performance compétitive vs Weaviate/Qdrant
- ▶ **50% Stockage** type halfvec (2-byte floats)
- ► Pas de Surfiltre Modes relaxed/strict

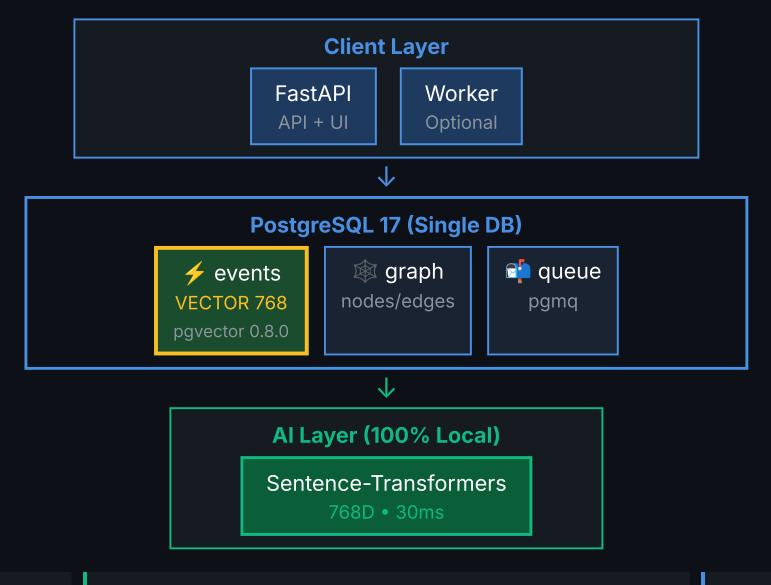
### **EXPLOSION ADOPTION ENTERPRISE**

- Supabase valorisation \$2B (avril 2025)
- Neon acquis par Databricks (\$1B, mai 2025)
- ► Databricks + Snowflake acquisitions startups PG
- ► 60-80% Réduction Coûts vs DB dédiées

**©** PostgreSQL est MAINTENANT le standard pour la recherche vectorielle

MnemoLite surfe cette vague PARFAITEMENT

### **PARCHITECTURE MNEMOLITE V1.3.0**



pgvector 0.8.0
9.4× plus rapide

**Single DB**Vector + Graph + Queue

**100% Local**Zero external APIs

© 2 containers (3 avec worker) • 1 database • 0 external APIs

### **TECH STACK 2025 - 100% LOCAL**

#### **BACKEND**

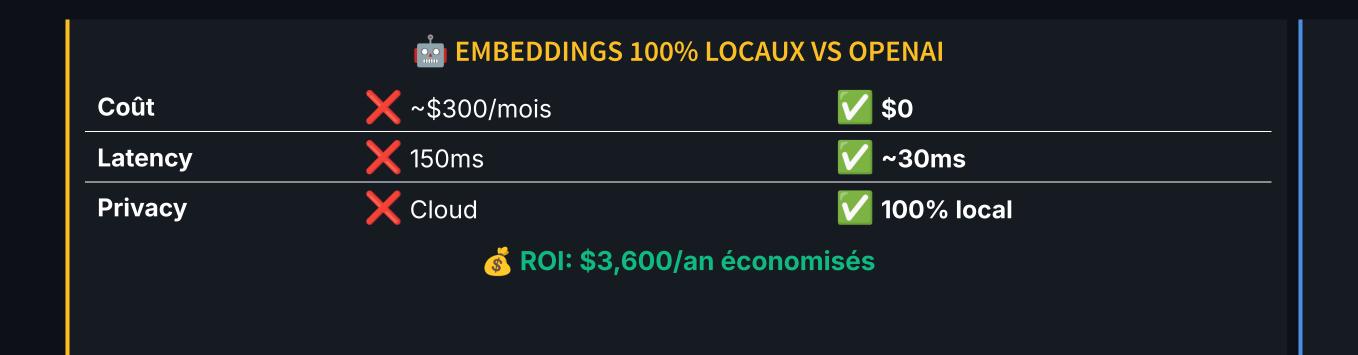
- ► FastAPI 0.111+
- ► SQLAlchemy 2.0+
- asyncpg
- ► Pydantic v2

#### **DATABASE**

- ► PostgreSQL 17
- pgvector 0.8.0
- pg\_partman
- pgmq

#### AI / EMBEDDINGS

- ▶ Sentence-Transformers
- nomic-embed-text-v1.5
- ▶ 768D, Apache 2.0
- ▶ ~30ms, 50-100 emb/s





Nomic v2 (Q2 2025)

→ Upgrade path ready

#### **Alternatives:**

- BGE-M3 (multi-lingual)
  - E5 (Microsoft)
  - MiniLM (compact)

**Gold Proposition : Gold Pr** 

## UI V4.0 - DESIGN SCADA INDUSTRIEL

#### **PRINCIPES SCADA**

- Zero border-radius
- Ultra dark palette
- ▶ Border-left accents
- Compact spacing
- ► Fast transitions (80ms)
- ► High info density

#### **ARCHITECTURE MODULAIRE**

- ▶ 17 modules CSS
- ▶ 6 modules JavaScript
- ▶ 0 ligne inline JS
- ► HTMX 2.0
- ► Full ARIA









## DÉMARRAGE RAPIDE (< 2 MINUTES)

#### **CONFIGURATION (.ENV)**

- ▶ POSTGRES\_PASSWORD: votre\_mot\_de\_passe
- ► EMBEDDING\_MODEL: nomic-ai/nomic-embed-text-v1.5
- ► ENVIRONMENT: development production





### DEMO: DASHBOARD & RECHERCHE HYBRIDE

Dashboard: localhost:8001/ui/

#### DASHBOARD LIVE

- 1. 7 Période "24h" → HTMX update
- 2.  $\bigcirc$  Filtrer projet  $\rightarrow$  instantané
- 3.  $\blacksquare$  Event card  $\rightarrow$  modal JSON
- 4. 

  Network: zéro reload
- **HTMX 2.0: Updates partiels HTML**

Search: localhost:8001/ui/search

### RECHERCHE SÉMANTIQUE

Vector: "integration tests failing"

Project: Expanse

Category: bug

Threshold: 0.8 (strict)

→ 8 events en ~9ms ۶

Threshold: 0.8 (strict) | 1.0 (balanced) | 1.2 (relaxed)

Deux démos clés: Ul moderne (HTMX) + Recherche puissante (hybrid search)

### DEMO: GRAPH DE CONNAISSANCES

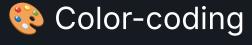
LIVE: http://localhost:8001/ui/graph

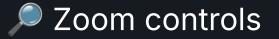
#### **INTERACTIONS LIVE:**

- 1.  $\blacksquare$  Changer layout:  $cose \rightarrow circle \rightarrow grid$
- 2. Filtrer par type: désactiver "concepts"
- 4. 

  Hover → tooltip infos









**LIVE:** http://localhost:8001/ui/monitoring



ECharts line chart - Events/day



By Type • By Project (Pie charts)



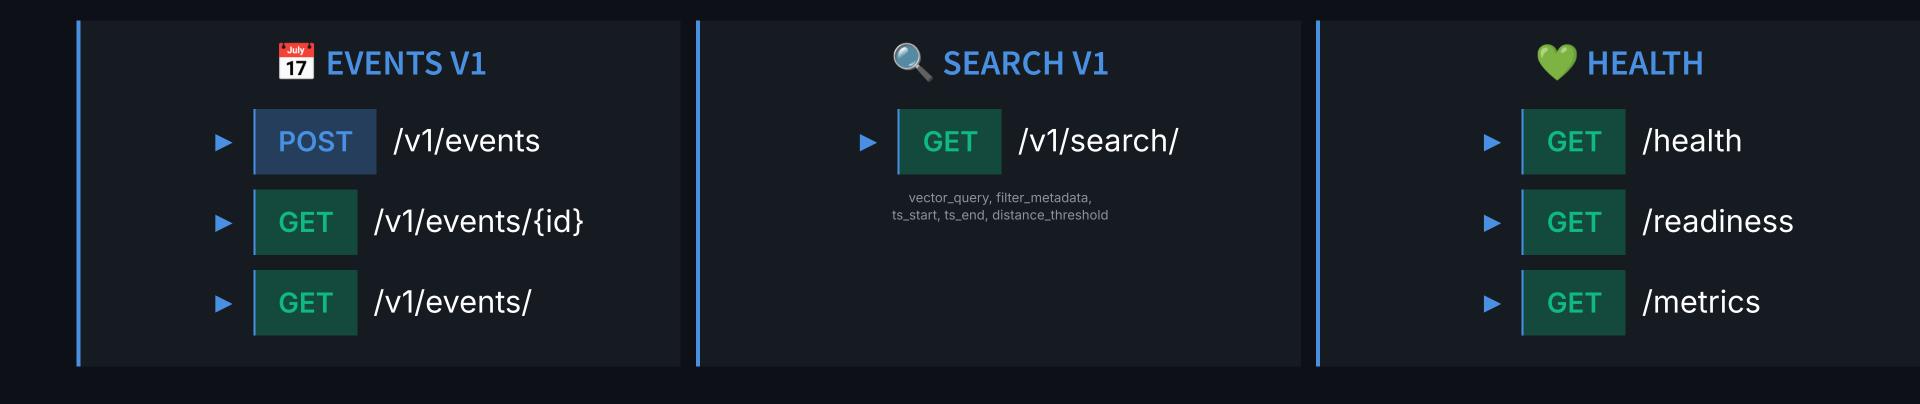
Last 24h alerts (ERROR, CRITICAL)



30s (pause when hidden - Visibility API)

## API REST - OPENAPI 3.1

Swagger UI: http://localhost:8001/docs



## **PERFORMANCE EXCEPTIONNELLE (PGVECTOR 0.8.0)**

#### MNEMOLITE (PG17 + PGVECTOR 0.8.0)

Hybrid Search	<b>11ms</b> P50: 7ms
Vector Search	<b>12ms</b> P50: 8ms
Metadata + Time	3ms P50: 2ms

**◎** <15ms P95: ATTEINT **▽** 

#### **COMPARAISON 2025 (BENCHMARKS RÉELS)**

pgvector 0.8.0	<b>9.4× plus rapide</b> (vs 0.7.4)			
vs Weaviate	243% plus rapide (Timescale)			
vs Pinecone	pgvectorscale surpasse			
Throughput: 3-5× en production				



#### **SECRET SAUCE PGVECTOR 0.8.0:**

- **► Scans itératifs** → Pas de surfiltre
- ► halfvec type → 50% stockage économisé

- ► HNSW + JSONB → Combo PostgreSQL natif
- **▶ Optimisation query plan** → Estimation coûts

Environnement: Local machine, ~50k events, non-partitioned Performance scalée avec partitioning @500k+



**178** 

**Tests Totaux** 

100%

Pass Rate

~13s

Duration

~87%

Coverage

#### **TYPES DE TESTS:**

- ► **!** Repository: Event, Memory
- ► ★ Services: Embedding, Search
- ► Routes: Events, Search, Health, Ul
- ▶ 💾 Database: Schema, indexes

CI/CD Ready: pytest-asyncio, Docker-based, Makefile

## DÉPLOIEMENT PRODUCTION

```
# docker-compose.yml (Production)
services:
   postgres:
    image: pgvector/pgvector:pg17
   volumes: ./data:/var/lib/postgresql
   restart: always

api:
   build: ./api
   environment:
    - ENVIRONMENT=production
   - LOG LEVEL=INFO
```

### **SÉCURITÉ**

- ► PostgreSQL auth
- ► API CORS config
- ► Env variables (.env)

### **MONITORING**

- /health endpoint
- /metrics (Prometheus)
- Structured logging

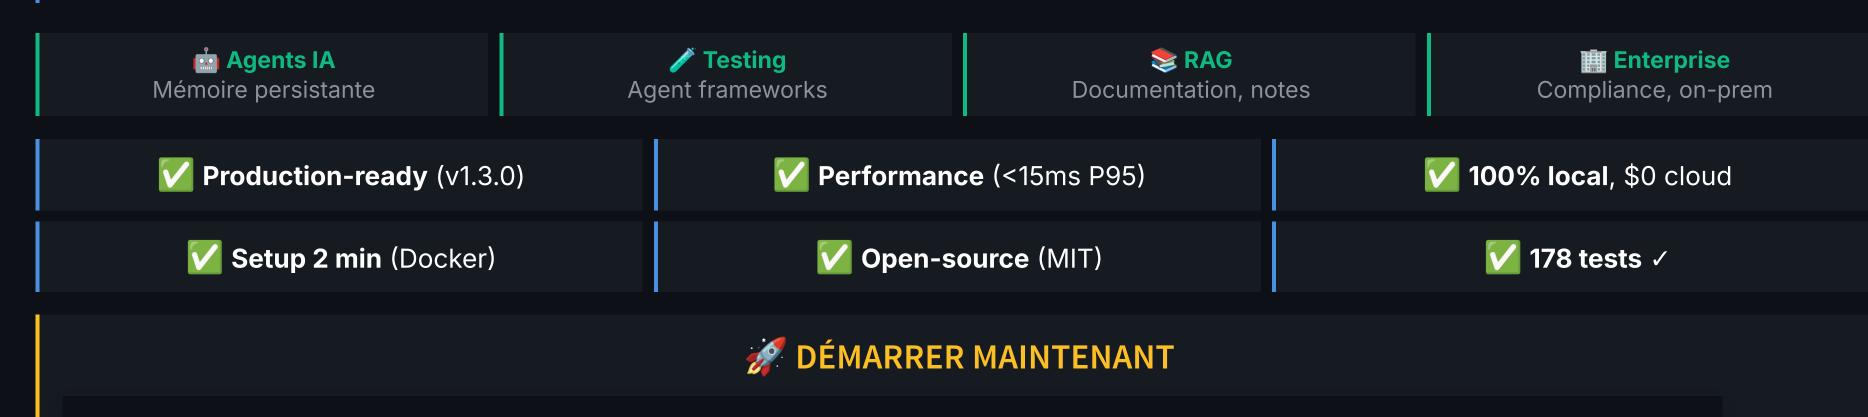


- ► Current: <500k events
- @500k: pg\_partman
- ► Future: INT8 quant

# MNEMOLITE VS CONCURRENTS 2025

Critère	Pinecone	Weaviate	Qdrant	ChromaDB	MnemoLite	
Coût	>\$500/mo @scale	\$25-153/mo cloud	\$102/mo AWS	FREE	\$0	
P95 Latency	50-200ms	30-100ms	20-50ms	Varies	<15ms	
Setup	Easy	Medium	Medium	pip install	make up	
Local Deploy	X					
Scaling	Cloud Auto	Horizontal	Horizontal	Single-node	<500k optimal	
Graph Support	X	Partial	X	X	✓ Native	
Lock-in	High	Medium	Medium	Zero	Zero	
vs ChromaDB: Production-ready (vs single-node) + Graph			h	vs Qdrant: Simpler (PostgreSQL) + \$0 vs \$102/mo		
vs Pinecone: 100% local + \$0 vs >\$500/mo				Sweet Spot: 10k-500k events, local, privacy		

## MNEMOLITE: MÉMOIRE COGNITIVE SIMPLIFIÉE



- \$ git clone https://github.com/giak/MnemoLite.git
- \$ cd MnemoLite && make up
- \$ open http://localhost:8001/ui/

State - Docs: README.md • GUIDE\_DEMARRAGE.md | W GitHub: github.com/giak/MnemoLite | License: MIT

\* Sweet Spot: 10k-500k events • local • privacy-critical

